

UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
DIRETORIA DE PESQUISA E PÓS GRADUAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

JÔNATAS TRABUCO BELOTTI

**IMPLEMENTAÇÃO PROJETO PRÁTICO 5.9: MLP PARA
CLASSIFICAÇÃO DE PADRÕES**

RELATÓRIO

PONTA GROSSA
2017

JÔNATAS TRABUCO BELOTTI

**IMPLEMENTAÇÃO PROJETO PRÁTICO 5.9: MLP PARA
CLASSIFICAÇÃO DE PADRÕES**

Relatório apresentado como requisito parcial à obtenção de nota na disciplina de Fundamentos de Redes Neurais Artificiais do Programa de Pós-Graduação em Engenharia Elétrica, da Universidade Tecnológica Federal do Paraná–Campus Ponta Grossa.

Professor: Prof. Dr. Sérgio Okida

**PONTA GROSSA
2017**

SUMÁRIO

1	INTRODUÇÃO	3
1.1	ESTUDO DE CASO	3
2	DESENVOLVIMENTO DO PROJETO	5
2.1	TREINAMENTO COM ALGORITMO <i>BACKPROPAGATION</i>	5
2.2	TREINAMENTO COM ALGORITMO <i>BACKPROPAGATION</i> COM <i>MOMENTUM</i>	7
2.3	ANÁLISE DOS TREINAMENTOS	8
2.4	TESTE DA REDE	9
3	CONCLUSÃO	11
	REFERÊNCIAS	12
	APÊNDICE A - IMPLEMENTAÇÃO DA CLASSE MLP EM JAVA	13
	ANEXO A - CONJUNTO DE TREINAMENTO	24
	ANEXO B - CONJUNTO DE TESTE	28

1 INTRODUÇÃO

O *Perceptron* de Múltiplas Camadas (PMC, ou MLP do inglês *Multilayer Perceptron*) é constituído por um conjunto de neurônios artificiais dispostos em varias camadas, de modo que o sinal de entrada se propaga para frente através da rede, camada por camada. Dentre suas camadas existe a camada de entrada que recebe os sinais de entrada, a camada de saída que entrega o resultado obtido pela rede e no meio dessas podem existir quantas camadas forem necessárias. Essas camadas são chamadas intermediárias ou ocultas (HAYKIN, 2001). Note que uma MLP é constituída de pelo menos 2 camadas neurais, sendo uma camada de saída e pelo menos 1 camada escondida (SILVA; SPATTI; FLAUZINO, 2010).

As MLPs são consideradas uma das arquiteturas mais versáteis quanto a aplicabilidade, sendo utilizadas em diversas áreas do conhecimento. Dentre as utilizações da MLP estão: aproximação universal de funções, reconhecimento de padrões, identificação e controle de processos, previsão de series temporais e otimização de sistemas (SILVA; SPATTI; FLAUZINO, 2010).

Esse relatório tem como objetivo descrever o desenvolvimento do Projeto Prático 5.9 do livro *Redes neurais artificiais para engenharia e ciências aplicadas* de Silva, Spatti e Flauzino (2010), o projeto consiste na implementação, treinamento e teste de uma rede neural do tipo *Perceptron* Multicamadas para ser usada como classificadora de padrões com o objetivo de auxiliar no processamento de bebidas.


1.1 ESTUDO DE CASO

O projeto prático 5.9 do livro *Redes neurais artificiais para engenharia e ciências aplicadas* de Silva, Spatti e Flauzino (2010), mostra que no processamento de bebidas, é aplicado um conservante à bebida em função da análise de 4 características medidas em cada lote de bebida, definidas por x_1 (teor de água), x_2 (grau de acidez), x_3 (temperatura) e x_4 (tensão interfacial). Existem apenas 3 possibilidades de conservantes para serem adicionados as bebidas, denotados por **A**, **B** e **C**.

O objetivo do projeto é o desenvolvimento, treinamento e teste de uma MLP que determine qual dos conservantes deve ser adicionado a cada lote de bebida a partir da análise das 4 características medidas. É determinada que a arquitetura da rede, que deve conter 4 sinais de entrada, 2 camadas neurais, sendo 15 neurônios na camada escondida e 3 neurônios na camada de saída. A Figura 1 mostra detalhadamente a arquitetura que a MLP deve ter para a realização do projeto.

Analisando a arquitetura proposta na Figura 1 nota-se que a MLP possuirá 3 sinais de saída, como a resposta da MLP deve ser o tipo de conservante (A, B ou C) se faz necessário padronizar quais combinações de saída representarão cada conservante. Essa padronização pode

Figura 1 – Arquitetura proposta rede *Perceptron* Multicamadas



Fonte: (SILVA; SPATTI; FLAUZINO, 2010).

ser vista na Tabela 1.

Tabela 1 – Padronização da saída da MLP

Tipo de conservante	y_1	y_2	y_3
Tipo A	1	0	0
Tipo B	0	1	0
Tipo C	0	0	1

Fonte: Autoria própria.

2 DESENVOLVIMENTO DO PROJETO

A rede MLP proposta na Seção 2.4 foi desenvolvida na linguagem Java, a classe MLP é a responsável por implementar o funcionamento da rede, seu código fonte está disponível no Apêndice A. Com o intuito de facilitar o acesso a rede desenvolvida todo o código fonte, juntamente com o programa já compilado e os arquivos de treinamento e de teste estão disponíveis em um repositório do *GitHub* que pode ser acessado pelo link <<https://github.com/jonatastbelotti/MLPClassificacaoPadrao>>.

As seções 2.1, 2.2, 2.3 e 2.4 apresentam as discussões a respeito dos treinamentos e testes realizados na MLP.

2.1 TREINAMENTO COM ALGORITMO *BACKPROPAGATION*

A rede neural Perceptron Multicamadas foi treinada utilizando o algoritmo de aprendizagem *backpropagation*. Para tanto os pesos sinápticos iniciais foram gerados de forma aleatória com valores entre 0 e 1. Os valores iniciais dos pesos sinápticos são apresentados a seguir:

Pesos camada escondida:

```
N1 = 0,107536 0,287204 0,988448 0,269921 0,595165
N2 = 0,778432 0,468819 0,848750 0,809264 0,984074
N3 = 0,870440 0,929182 0,649449 0,641384 0,600356
N4 = 0,134505 0,718753 0,872210 0,824644 0,652206
N5 = 0,755379 0,247501 0,331459 0,701983 0,818383
N6 = 0,065348 0,447899 0,400095 0,730609 0,207458
N7 = 0,465652 0,559282 0,787082 0,451635 0,363438
N8 = 0,429271 0,148211 0,786839 0,353487 0,504985
N9 = 0,654516 0,102525 0,924824 0,307877 0,023243
N10 = 0,605466 0,607867 0,480391 0,517105 0,454927
N11 = 0,642867 0,624359 0,211529 0,400999 0,098983
N12 = 0,061225 0,929147 0,661139 0,761268 0,095299
N13 = 0,758948 0,876337 0,279626 0,420834 0,832334
N14 = 0,751103 0,656794 0,029495 0,689504 0,900353
N15 = 0,141663 0,346921 0,136945 0,501500 0,989760
```

Pesos camada de saída:

```
N1 = 0,355341 0,970452 0,581492 0,354469 0,143825 0,317984 0,156232
      0,780592 0,668531 0,642778 0,983764 0,386072 0,502407 0,639562
      0,392809 0,838261
N2 = 0,007120 0,355295 0,504662 0,657817 0,669543 0,870788 0,179184
```

0,216368 0,310969 0,790655 0,184540 0,033314 0,499279 0,606461
 0,415555 0,622651
 N3 = 0,772612 0,721538 0,466979 0,192461 0,217666 0,555839 0,505676
 0,957716 0,536568 0,685324 0,179671 0,691314 0,983315 0,412770
 0,252200 0,408747

Foram utilizadas uma taxa de aprendizagem $\eta = 0,1$ e uma precisão de $\varepsilon = 10^{-6}$. O conjunto de dados utilizado para o treinamento da MLP está disponível no Anexo A.

A rede foi iniciada com um Erro quadrático médio de $E_{qm} = 0,969800$ e ao final de 7,13 segundos o treinamento foi finalizado, tendo levado 1167 épocas para obter $E_{qm} = 0,025987$. Os pesos sinápticos obtidos ao final do treinamento foram:

Pesos camada escondida:

N1 = -1,510861 0,088077 0,566373 -0,324799 0,183600
 N2 = 9,523669 2,555060 3,787443 4,998849 3,577444
 N3 = 7,589782 3,520399 5,458402 5,619990 3,920627
 N4 = 4,907093 2,808587 4,240590 3,951884 2,922394
 N5 = 4,963422 2,221356 4,043916 3,976752 3,265644
 N6 = -0,226388 0,561020 0,857369 0,641873 0,383079
 N7 = 6,813671 2,049162 2,741281 3,374751 2,467509
 N8 = 0,066571 0,249918 1,001865 0,292513 0,644953
 N9 = 0,548289 -0,229772 0,527223 -0,181457 -0,468084
 N10 = -1,980162 -0,423890 -1,213491 -1,518960 -1,018689
 N11 = 4,743890 1,693819 1,762479 2,292896 1,713066
 N12 = 4,001849 1,457595 1,813445 2,198073 1,125105
 N13 = 5,027010 1,727022 1,737807 2,292377 2,174540
 N14 = 5,671584 1,716370 1,858657 2,760279 2,490358
 N15 = -2,381570 -0,745227 -1,577350 -1,661411 -0,724918

Pesos camada de saída:

N1 = -2,935681 0,996104 -3,221576 -4,831441 -2,296207 -3,823373 -0,643523
 -1,742724 -0,262937 0,455740 2,399089 -1,341618 -1,948689 -1,811138
 -1,974467 2,733235
 N2 = 2,840502 -1,615977 -7,153427 8,517873 5,696752 4,820299 -1,341960
 -4,811377 -1,422140 -0,161324 -0,825257 -3,281889 -2,147716 -3,096454
 -3,801467 -0,563837
 N3 = 6,791618 -1,701707 5,681341 1,158218 -1,585635 1,801072 -0,655237
 4,039734 -0,323526 -0,677612 -3,162048 2,678222 2,728488 3,157097
 3,287382 -3,453343

2.2 TREINAMENTO COM ALGORITMO *BACKPROPAGATION* COM *MOMENTUM*

A MLP também foi treinada com a utilização do algoritmo de aprendizagem *backpropagation* com *momentum*, que é uma variação do algoritmo de aprendizagem *backpropagation* utilizada na Seção 2.1. Para esse treinamento foram utilizadas as mesmas matrizes de pesos sinápticos iniciais geradas no treinamento da Seção 2.1. Foram utilizadas uma taxa de aprendizagem $\eta = 0,1$, uma precisão de $\varepsilon = 10^{-6}$ e fator *momentum* de $\alpha = 0,9$.

A rede foi iniciada com um Erro quadrático médio de $E_{qm} = 0,969800$ e ao final de 1,63 segundos o treinamento foi finalizado, tendo levado 285 épocas para obter $E_{qm} = 0,027476$. Os pesos sinápticos obtidos ao final do treinamento foram:

Pesos camada escondida:

```
N1 = 0,364231 -0,101421 0,478615 -0,515954 0,050560
N2 = 5,744250 1,212367 2,394739 3,021475 2,333066
N3 = 3,580229 1,993885 2,992756 3,151278 2,242548
N4 = 5,273199 2,790674 3,928003 4,560609 3,062594
N5 = 4,146302 0,870298 1,483484 2,253496 1,862166
N6 = 0,285704 0,087872 -0,111363 -0,103668 -0,338788
N7 = 2,588926 0,737709 1,262036 1,129330 0,830946
N8 = 1,320428 0,101101 0,805437 0,294167 0,504498
N9 = 1,388367 0,114231 1,003829 0,358607 0,047355
N10 = 1,612350 0,604587 0,545561 0,574071 0,535121
N11 = 1,439040 0,728675 0,331504 0,470565 0,230423
N12 = 0,867900 0,859955 0,680834 0,720724 0,019922
N13 = 4,175834 1,413048 1,391555 1,865061 1,814576
N14 = 4,111459 1,247607 1,159302 2,066459 1,907613
N15 = -0,005413 -0,131148 -0,702680 -0,600535 0,227005
```

Pesos camada de saída:

```
N1 = -9,858128 0,740417 -7,236521 -8,399917 -4,192569 -4,444404 1,294910
    -2,781377 -0,872503 -0,849482 -0,765183 -0,037756 -1,061603 -4,119547
    -3,645823 2,788173
N2 = 4,792244 -1,954569 -9,790357 9,205573 19,638707 -6,618097 -1,602220
    -4,128565 -2,710568 -2,269847 -2,980937 -2,647401 -0,663291 -6,989166
    -6,994032 -1,123327
N3 = 15,010818 -2,783439 9,925807 4,975526 -2,800946 7,104502 -2,854327
    3,528069 0,093214 0,188790 0,927912 0,314883 -0,053431 6,482948
    6,376826 -3,627838
```

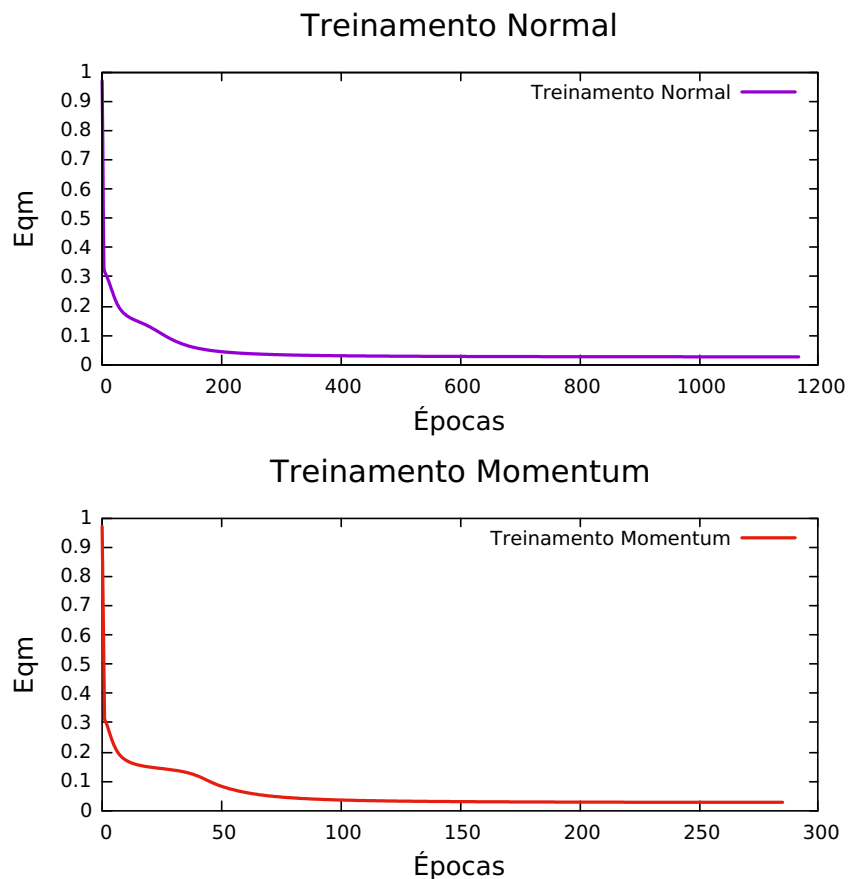

2.3 ANÁLISE DOS TREINAMENTOS

Perceba que apesar de os 2 treinamentos das seções 2.1 e 2.2 terem sido iniciados com as mesmas matrizes de pesos sinápticos, as matrizes de pesos sinápticos resultantes, o Erro quadrático médio resultante, o número de épocas necessárias para o treinamento e o tempo necessário para o treinamento foram diferentes.

A adição do termo de *momentum* no treinamento da MLP resulta no aceleração da conversão dos pesos sinápticos para os valores finais. De forma que quanto mais longe os pesos sinápticos estiverem dos valores finais maior será o ajuste sofrido por eles (SILVA; SPATTI; FLAUZINO, 2010). Isso fica evidente ao compararmos o número de épocas do treinamento sem *momentum* (1167 épocas) com o número de épocas do treinamento com *momentum* (285 épocas), a aceleração do treinamento pelo termo de *momentum* gerou um treinamento com 882 épocas a menos. Consequentemente, menos épocas resultam em um menor tempo necessário para o treinamento.

Os gráficos da Figura 2 apresentam a relação dos valores de Erro quadrático médio em função de cada época de treinamento, tanto para o treinamento com *momentum* como sem.

Figura 2 – Comparação dos treinamentos



Fonte: Autoria própria.

Analisando os gráficos da Figura 2 nota-se que o comportamento das duas curvas são

similares, ambas tem um período onde a velocidade de decaimento do E_{qm} é maior, e ao decorrer das épocas essa velocidade vai diminuindo até ser menor que a precisão estabelecida e o treinamento ter então o seu fim. No treinamento com *momentum* o período com maior velocidade de decaimento do E_{qm} vai da época 0 até a época 50, por sua vez no treinamento sem *momentum* esse período é compreendido entre as épocas 0 e 200.

Pelos gráficos da Figura 2 mais uma vez é possível notar que a velocidade de decaimento do E_{qm} é maior no treinamento realizado pelo algoritmo *backpropagation* com *momentum*.

2.4 TESTE DA REDE

Após o treinamento da rede a mesma foi submetida a um teste, com o objetivo de validar o poder de abstração da rede obtido pelo processo de treinamento. O teste foi realizado mediante a comparação dos valores fornecidos pela rede com os valores desejados para cada amostra de teste. A Tabela 2 apresenta o conjunto de teste utilizado. Esse mesmo conjunto de teste está disponível no Anexo B.

Tabela 2 – Conjunto de padrões de teste

Amostra	x_1	x_2	x_3	x_4	d_1	d_2	d_3
1	0,8622	0,7101	0,6236	0,7894	0	0	1
2	0,2741	0,1552	0,1333	0,1516	1	0	0
3	0,6772	0,8516	0,6543	0,7573	0	0	1
4	0,2178	0,5039	0,6415	0,5039	0	1	0
5	0,7260	0,7500	0,7007	0,4953	0	0	1
6	0,2473	0,2941	0,4248	0,3087	1	0	0
7	0,5682	0,5683	0,5054	0,4426	0	1	0
8	0,6566	0,6715	0,4952	0,3951	0	1	0
9	0,0705	0,4717	0,2921	0,2954	1	0	0
10	0,1187	0,2568	0,3140	0,3037	1	0	0
11	0,5673	0,7011	0,4083	0,5552	0	1	0
12	0,3164	0,2251	0,3526	0,2560	1	0	0
13	0,7884	0,9568	0,6825	0,6398	0	0	1
14	0,9633	0,7850	0,6777	0,6059	0	0	1
15	0,7739	0,8505	0,7934	0,6626	0	0	1
16	0,4219	0,4136	0,1408	0,0940	1	0	0
17	0,6616	0,4365	0,6597	0,8129	0	0	1
18	0,7325	0,4761	0,3888	0,5683	0	1	0

Fonte: Adaptado de Silva, Spatti e Flauzino (2010).

A rede foi testada tanto com o treinamento realizado por meio do algoritmo de aprendizagem *backpropagation* (Seção 2.1) como com o treinamento realizado por meio do algoritmo de aprendizagem *backpropagation* com *momentum* (Seção 2.2). Os resultados obtidos pelos pesos de cada treinamento para cada uma das amostras de teste da Tabela 2 podem ser vistos na Tabela 3.

Tabela 3 – Conjunto de padrões de teste

Amostra	d_1	d_2	d_3	<i>Backpropagation</i>			<i>Momentum</i>		
				$y_1^{\text{pós}}$	$y_2^{\text{pós}}$	$y_3^{\text{pós}}$	$y_1^{\text{pós}}$	$y_2^{\text{pós}}$	$y_3^{\text{pós}}$
1	0	0	1	0	0	1	0	0	1
2	1	0	0	1	0	0	1	0	0
3	0	0	1	0	0	1	0	0	1
4	0	1	0	0	1	0	0	1	0
5	0	0	1	0	0	1	0	0	1
6	1	0	0	1	0	0	1	0	0
7	0	1	0	0	1	0	0	1	0
8	0	1	0	0	1	0	0	1	0
9	1	0	0	1	0	0	1	0	0
10	1	0	0	1	0	0	1	0	0
11	0	1	0	0	1	0	0	1	0
12	1	0	0	1	0	0	1	0	0
13	0	0	1	0	0	1	0	0	1
14	0	0	1	0	0	1	0	0	1
15	0	0	1	0	0	1	0	0	1
16	1	0	0	1	0	0	1	0	0
17	0	0	1	0	0	1	0	0	1
18	0	1	0	0	1	0	0	1	0
Total de acertos (%)				100%			100%		

Fonte: Autoria própria.

Na Tabela 3 além da resposta fornecida pela MLP (após o pós-processamento) mediante cada treinamento é possível verificar o percentual de acerto de cada treinamento. Apesar dos valores de Erro quadrático médio obtidos pelos treinamentos com o algoritmo *backpropagation* e *backpropagation* com *momentum* terem sido diferentes, os 2 treinamentos apresentaram o mesmo resultado no teste, ambos obtiveram porcentagem de acertado de 100% em todos os testes realizados.

3 CONCLUSÃO

Foi desenvolvida uma rede neural Perceptron multicamadas composta por 4 sinais de entrada, 1 camada escondida com 15 neurônios e 1 camada de saída com 3 neurônio para ser usada como classificadora de padrões no processo de produção de bebidas. A rede foi treinada utilizando o algoritmo de aprendizagem *backpropagation* obtendo $E_{qm} = 0,025987$ ao final de 1167 épocas de treinamento. Também foi realizado um treinamento com o algoritmo de aprendizagem *backpropagation* com *momentum*, obtendo $E_{qm} = 0,027476$ ao fim de 285 épocas.

Conclui-se que o melhor treinamento para a MLP proposta é o obtido através do algoritmo de aprendizagem *backpropagation* com *momentum*, pois apesar dos 2 treinamentos terem obtido porcentagem de acerto de 100% nos testes o treinamento com *momentum* foi executado com 882 épocas a menos.

REFERÊNCIAS

HAYKIN, Simon. **Redes Neurais: principios e prática**. 2. ed. Porto Alegre: Bookman, 2001. ISBN 978-85-7307-718-6.

SILVA, Ivan Nunes da; SPATTI, Danilo Hernane; FLAUZINO, Rogério Andrade. **Redes Neurais Artificiais Para Engenharia e Cincias Aplicadas - Curso Pratico**. 1. ed. São Paulo: ARTLIBER, 2010. ISBN 978-85-88098-53-4.

APÊNDICE A - IMPLEMENTAÇÃO DA CLASSE MLP EM JAVA

```

1 package Modelo;
2
3     import Controle.Comunicador;
4     import Recursos.Arquivo;
5     import java.io.BufferedReader;
6     import java.io.FileNotFoundException;
7     import java.io.FileReader;
8     import java.io.IOException;
9     import java.util.Random;
10
11     /**
12      *
13      * @author Jônatas Trabuco Belotti [jonatas.t.belotti@hotmail.com]
14      */
15     public class MLP {
16
17         public static final int NUM_ENTRADAS = 4;
18         private final int NUM_NEU_CAMADA_ESCONDIDA = 15;
19         public static final int NUM_NEU_CAMADA_SAIDA = 3;
20         private final double TAXA_APRENDIZAGEM = 0.1;
21         private final double PRECISAO = 0.000001;
22         private final double FATOR_MOMENTUM = 0.9;
23         private final double BETA = 1.0;
24
25         private int numEpocas;
26         private double fatorMomentum;
27         private double[] entradas;
28         private double[][] pesosCamadaEscondidaInicial;
29         private double[][] pesosCamadaEscondida;
30         private double[][] pesosCamadaEscondidaProximo;
31         private double[][] pesosCamadaEscondidaAnterior;
32         private double[][] pesosCamadaSaidaInicial;
33         private double[][] pesosCamadaSaida;
34         private double[][] pesosCamadaSaidaProximo;
35         private double[][] pesosCamadaSaidaAnterior;
36         private double[] potencialCamadaEscondida;
37         private double[] saidaCamadaEscondida;
38         private double[] potencialCamadaSaida;
39         private double[] saidaCamadaSaida;

```

```

40     private double[] saidaEsperada;
        private double[] gradienteCamadaSaida;
42     private double[] gradienteCamadaEscondida;

44     public MLP() {
        Random random;

46
        entradas = new double[NUM_ENTRADAS + 1];
48     pesosCamadaEscondidaInicial = new double[
        NUM_NEU_CAMADA_ESCONDIDA][NUM_ENTRADAS + 1];
        pesosCamadaEscondida = new double[NUM_NEU_CAMADA_ESCONDIDA][
        NUM_ENTRADAS + 1];
50     pesosCamadaEscondidaAnterior = new double[
        NUM_NEU_CAMADA_ESCONDIDA][NUM_ENTRADAS + 1];
        pesosCamadaEscondidaProximo = new double[
        NUM_NEU_CAMADA_ESCONDIDA][NUM_ENTRADAS + 1];
52     pesosCamadaSaidaInicial = new double[NUM_NEU_CAMADA_SAIDA][
        NUM_NEU_CAMADA_ESCONDIDA + 1];
        pesosCamadaSaida = new double[NUM_NEU_CAMADA_SAIDA][
        NUM_NEU_CAMADA_ESCONDIDA + 1];
54     pesosCamadaSaidaAnterior = new double[NUM_NEU_CAMADA_SAIDA][
        NUM_NEU_CAMADA_ESCONDIDA + 1];
        pesosCamadaSaidaProximo = new double[NUM_NEU_CAMADA_SAIDA][
        NUM_NEU_CAMADA_ESCONDIDA + 1];
56     potencialCamadaEscondida = new double[NUM_NEU_CAMADA_ESCONDIDA
        + 1];
        saidaCamadaEscondida = new double[NUM_NEU_CAMADA_ESCONDIDA +
        1];
58     potencialCamadaSaida = new double[NUM_NEU_CAMADA_SAIDA];
        saidaCamadaSaida = new double[NUM_NEU_CAMADA_SAIDA];
60     saidaEsperada = new double[NUM_NEU_CAMADA_SAIDA];
        gradienteCamadaSaida = new double[NUM_NEU_CAMADA_SAIDA];
62     gradienteCamadaEscondida = new double[NUM_NEU_CAMADA_ESCONDIDA
        ];

64     //Iniciando pesos sinapticos
        Comunicador.iniciarLog("Iniciando os pesos sinapticos");
66     random = new Random();

68     for (int i = 0; i < NUM_NEU_CAMADA_ESCONDIDA; i++) {
        for (int j = 0; j < NUM_ENTRADAS + 1; j++) {
70         pesosCamadaEscondidaInicial[i][j] = random.nextDouble();

```

```

    }
72 }

74 for (int i = 0; i < NUM_NEU_CAMADA_SAIDA; i++) {
    for (int j = 0; j < NUM_NEU_CAMADA_ESCONDIDA + 1; j++) {
76         pesosCamadaSaidaInicial[i][j] = random.nextDouble();
    }
78 }

80 copiarMatriz(pesosCamadaEscondidaInicial, pesosCamadaEscondida)
    ;
    copiarMatriz(pesosCamadaSaidaInicial, pesosCamadaSaida);
82 imprimirPesos();
}

84 public boolean treinar(Arquivo arquivoTreinamento) {
86     Comunicador.limparLog();
    return treinar(arquivoTreinamento, false);
88 }

90 public boolean treinar(Arquivo arquivoTreinamento, boolean
    momentum) {
    FileReader arq;
92     BufferedReader lerArq;
    String linha;
94     double erroAtual;
    double erroAnterior;
96     long tempInicial;

98     copiarMatriz(pesosCamadaEscondidaInicial, pesosCamadaEscondida)
        ;
    copiarMatriz(pesosCamadaSaidaInicial, pesosCamadaSaida);
100     copiarMatriz(pesosCamadaEscondidaInicial,
        pesosCamadaEscondidaAnterior);
    copiarMatriz(pesosCamadaSaidaInicial, pesosCamadaSaidaAnterior)
        ;

102     tempInicial = System.currentTimeMillis();
104     numEpocas = 0;
    erroAtual = erroQuadraticoMedio(arquivoTreinamento);

106     if (!momentum) {

```



```

108     fatorMomentum = 0D;
        Comunicador.iniciarLog("Início treinamento da MLP");
110 } else {
        fatorMomentum = FATOR_MOMENTUM;
112     Comunicador.iniciarLog("Início treinamento com MOMENTUM da
        MLP");
    }

114
    Comunicador.addLog(String.format("Erro inicial: %.6f",
        erroAtual).replace(".", ","));
116    imprimirPesos();
    Comunicador.addLog("Época Eqm");
118
    try {
120        do {
            this.numEpocas++;
122            erroAnterior = erroAtual;
            arq = new FileReader(arquivoTreinamento.getCaminhoCompleto
                ());
124            lerArq = new BufferedReader(arq);

126            linha = lerArq.readLine();
            if (linha.contains("x1")) {
128                linha = lerArq.readLine();
            }

130
            while (linha != null) {
132                separarEntradas(linha);

134                calcularSaidas();

136                ajustarPesos();

138                linha = lerArq.readLine();
            }

140
            arq.close();
            erroAtual = erroQuadraticoMedio(arquivoTreinamento);
            Comunicador.addLog(String.format("%d    %.6f", numEpocas,
                erroAtual).replace(".", ","));
144        } while (Math.abs(erroAtual - erroAnterior) > PRECISAO &&
            numEpocas < 10000);

```

```

146     Comunicador.addLog(String.format("Fim do treinamento. (%.2fs)
        ", (double) (System.currentTimeMillis() - tempInicial) /
        1000D));
        imprimirPesos();
148     } catch (FileNotFoundException ex) {
        return false;
150     } catch (IOException ex) {
        return false;
152     }

154     return true;
    }

156     public boolean treinarMomentum(Arquivo arquivoTreinamento) {
158         return treinar(arquivoTreinamento, true);
    }

160     public void testar(Arquivo arquivoTreinamento) {
162         FileReader arq;
        BufferedReader lerArq;
164         String linha;
        String esperada;
166         String resposta;
        boolean errou;
168         int amostrasErradas;
        int numAmostras;
170         double porcAcerto;

172         numAmostras = 0;
        amostrasErradas = 0;

174         Comunicador.iniciarLog("Início teste da MLP");
        Comunicador.addLog("d1 d2 d3 -- y1 y2 y3");

178         try {
            arq = new FileReader(arquivoTreinamento.getCaminhoCompleto())
                ;
180            lerArq = new BufferedReader(arq);

182            linha = lerArq.readLine();
            if (linha.contains("x1")) {

```

```

184         linha = lerArq.readLine();
185     }
186
187     while (linha != null) {
188         numAmostras++;
189         separarEntradas(linha);
190
191         calcularSaidas();
192
193         esperada = "";
194         resposta = "";
195         errou = false;
196         for (int i = 0; i < NUM_NEU_CAMADA_SAIDA; i++) {
197             esperada += String.format("%.0f  ", saidaEsperada[i]);
198             resposta += String.format("%d  ", posProcessamento(
199                 saidaCamadaSaida[i]));
200
201             if (saidaEsperada[i] != posProcessamento(saidaCamadaSaida
202                 [i])) {
203                 errou = true;
204             }
205         }
206
207         if (errou) {
208             amostrasErradas++;
209         }
210
211         Comunicador.addLog(esperada + " -- " + resposta);
212
213         linha = lerArq.readLine();
214     }
215
216     arq.close();
217     porcAcerto = (100D / numAmostras) * ((numAmostras -
218         amostrasErradas));
219     Comunicador.addLog(String.format("Total de acertos: %d/%d
220         (%.2f%%)", (numAmostras - amostrasErradas), numAmostras,
221         porcAcerto));
222 } catch (FileNotFoundException ex) {
223 } catch (IOException ex) {
224 }
225 }

```

```

222     private double erroQuadraticoMedio(Arquivo arquivo) {
        FileReader arq;
224     BufferedReader lerArq;
        String linha;
226     int numAmostras;
        double erroMedio;
228     double valorParcial;

230     erroMedio = 0D;
        numAmostras = 0;

232

        try {
234             arq = new FileReader(arquivo.getCaminhoCompleto());
            lerArq = new BufferedReader(arq);

236

            linha = lerArq.readLine();
238             if (linha.contains("x1")) {
                linha = lerArq.readLine();
240             }

242             while (linha != null) {
                numAmostras++;
244                 separarEntradas(linha);

246                 calcularSaidas();

248                 //Calculando erro
                valorParcial = 0D;
250                 for (int i = 0; i < saidaCamadaSaida.length; i++) {
                    valorParcial = valorParcial + Math.pow((double) (
                        saidaEsperada[i] - saidaCamadaSaida[i]), 2D);
252                 }
                erroMedio = erroMedio + (valorParcial / 2D);

254

                linha = lerArq.readLine();
256             }

258             arq.close();
            erroMedio = erroMedio / (double) numAmostras;

260

        } catch (FileNotFoundException ex) {

```

```

262     } catch (IOException ex) {
263     }
264
265     return erroMedio;
266 }
267
268 private void separarEntradas(String linha) {
269     String[] vetor;
270     int i;
271
272     vetor = linha.split("\\s+");
273     i = 0;
274
275     if (vetor[0].equals("")) {
276         i = 1;
277     }
278
279     entradas[0] = -1.0;
280     for (int j = 1; j <= NUM_ENTRADAS; j++) {
281         entradas[j] = Double.parseDouble(vetor[i++].replace(",", "."));
282     }
283     for (int j = 0; j < NUM_NEU_CAMADA_SAIDA; j++) {
284         saidaEsperada[j] = Double.parseDouble(vetor[i++].replace(",", "."));
285     }
286 }
287
288 private void calcularSaidas() {
289     double valorParcial;
290
291     //Calculando saidas da camada escondida
292     saidaCamadaEscondida[0] = -1D;
293     potencialCamadaEscondida[0] = -1D;
294
295     for (int i = 1; i < saidaCamadaEscondida.length; i++) {
296         valorParcial = 0D;
297
298         for (int j = 0; j < entradas.length; j++) {
299             valorParcial += entradas[j] * pesosCamadaEscondida[i - 1][j];
300         }

```

```

302     potencialCamadaEscondida[i] = valorParcial;
        saidaCamadaEscondida[i] = funcaoLogistica(valorParcial);
304 }

306     //Calculando saida da camada de saída
    for (int i = 0; i < saidaCamadaSaida.length; i++) {
308         valorParcial = 0D;

310         for (int j = 0; j < saidaCamadaEscondida.length; j++) {
            valorParcial += saidaCamadaEscondida[j] * pesosCamadaSaida[
                i][j];
312         }

314         potencialCamadaSaida[i] = valorParcial;
            saidaCamadaSaida[i] = funcaoLogistica(valorParcial);
316     }
}

318 private void ajustarPesos() {
320     //Ajustando pesos sinapticos da camada de saída
    for (int i = 0; i < gradienteCamadaSaida.length; i++) {
322         gradienteCamadaSaida[i] = (saidaEsperada[i] -
            saidaCamadaSaida[i]) * funcaoLogisticaDerivada(
                potencialCamadaSaida[i]);

324         for (int j = 0; j < NUM_NEU_CAMADA_ESCONDIDA + 1; j++) {
            pesosCamadaSaidaProximo[i][j] = pesosCamadaSaida[i][j] +
326                 (fatorMomentum * (pesosCamadaSaida[i][j] -
                    pesosCamadaSaidaAnterior[i][j])) +
                    (TAXA_APRENDIZAGEM * gradienteCamadaSaida[i] *
                        saidaCamadaEscondida[j]);

328         }
    }

330     //Ajustando pesos sinapticos da camada escondida
    for (int i = 0; i < gradienteCamadaEscondida.length; i++) {
332         gradienteCamadaEscondida[i] = 0D;
        for (int j = 0; j < NUM_NEU_CAMADA_SAIDA; j++) {
334             gradienteCamadaEscondida[i] += gradienteCamadaSaida[j] *
                pesosCamadaSaida[j][i + 1];

336         }
    }

```

```

        gradienteCamadaEscondida[i] *= funcaoLogisticaDerivada(
            potencialCamadaEscondida[i + 1]);
338
        for (int j = 0; j < NUM_ENTRADAS + 1; j++) {
340            pesosCamadaEscondidaProximo[i][j] = pesosCamadaEscondida[i]
                [j] +
                (fatorMomentum * (pesosCamadaEscondida[i][j] -
                    pesosCamadaEscondidaAnterior[i][j])) +
342            (TAXA_APRENDIZAGEM * gradienteCamadaEscondida[i] *
                entradas[j]));
        }
344    }

346    //Copiando pesos
    copiarMatriz(pesosCamadaEscondida, pesosCamadaEscondidaAnterior
        );
348    copiarMatriz(pesosCamadaEscondidaProximo, pesosCamadaEscondida)
        ;
    copiarMatriz(pesosCamadaSaida, pesosCamadaSaidaAnterior);
350    copiarMatriz(pesosCamadaSaidaProximo, pesosCamadaSaida);
}

352
private void copiarMatriz(double[][] origem, double[][] destino)
{
354    for (int i = 0; i < origem.length; i++) {
        for (int j = 0; j < origem[i].length; j++) {
356            if (destino.length > i) {
                if (destino[i].length > j) {
358                    destino[i][j] = origem[i][j];
                }
360            }
        }
362    }
}

364
private double funcaoLogistica(double valor) {
366    return 1D / (1D + Math.pow(Math.E, -1D * BETA * valor));
}

368
private double funcaoLogisticaDerivada(double valor) {
370    return (BETA * Math.pow(Math.E, -1D * BETA * valor)) / Math.pow
        ((Math.pow(Math.E, -1D * BETA * valor) + 1D), 2D);

```

```

    }
372
    private int posProcessamento(double valor) {
374        int resposta = 0;

376        if (valor >= 0.5) {
            resposta = 1;
378        }

380        return resposta;
    }
382

    private void imprimirPesos() {
384        String log;

386        Comunicador.addLog("Pesos camada escondida:");

388        for (int i = 0; i < NUM_NEU_CAMADA_ESCONDIDA; i++) {
            log = "N" + (i + 1) + " =";
390

            for (int j = 0; j < NUM_ENTRADAS + 1; j++) {
392                log += String.format(" %f", pesosCamadaEscondida[i][j]);
            }

394            Comunicador.addLog(log);
396        }

398        Comunicador.addLog("Pesos camada de saída:");
        for (int i = 0; i < NUM_NEU_CAMADA_SAIDA; i++) {
400            log = "N" + (i + 1) + " =";

402            for (int j = 0; j < NUM_NEU_CAMADA_ESCONDIDA + 1; j++) {
                log += String.format(" %f", pesosCamadaSaida[i][j]);
404            }

406            Comunicador.addLog(log);
        }
408    }

410 }

```


ANEXO A - CONJUNTO DE TREINAMENTO

x1	x2	x3	x4	d1	d2	d3
0.3841	0.2021	0	0.2438	1.0000	0	0
0.1765	0.1613	0.3401	0.0843	1.0000	0	0
0.3170	0.5786	0.3387	0.4192	0	1.0000	0
0.2467	0.0337	0.2699	0.3454	1.0000	0	0
0.6102	0.8192	0.4679	0.4762	0	1.0000	0
0.7030	0.7784	0.7482	0.6562	0	0	1.0000
0.4767	0.4348	0.4852	0.3640	0	1.0000	0
0.7589	0.8256	0.6514	0.6143	0	0	1.0000
0.1579	0.3641	0.2551	0.2919	1.0000	0	0
0.5561	0.5602	0.5605	0.2105	0	1.0000	0
0.3267	0.2974	0.0343	0.1466	1.0000	0	0
0.2303	0.0942	0.3889	0.1713	1.0000	0	0
0.2953	0.2963	0.2600	0.3039	1.0000	0	0
0.5797	0.4789	0.5780	0.3048	0	1.0000	0
0.5860	0.5250	0.4792	0.4021	0	1.0000	0
0.7045	0.6933	0.6449	0.6623	0	0	1.0000
0.9134	0.9412	0.6078	0.5934	0	0	1.0000
0.2333	0.4943	0.2525	0.2567	1.0000	0	0
0.2676	0.4172	0.2775	0.2721	1.0000	0	0
0.4850	0.5506	0.5269	0.6036	0	1.0000	0
0.2434	0.2567	0.2312	0.2624	1.0000	0	0
0.1250	0.3023	0.1826	0.3168	1.0000	0	0
0.5598	0.4253	0.4258	0.3192	0	1.0000	0
0.5738	0.7674	0.6154	0.4447	0	0	1.0000
0.5692	0.8368	0.5832	0.4585	0	0	1.0000
0.4655	0.7682	0.3221	0.2940	0	1.0000	0
0.5568	0.7592	0.6293	0.5453	0	1.0000	0
0.8842	0.7509	0.5723	0.5814	0	0	1.0000
0.7959	0.9243	0.7339	0.7334	0	0	1.0000
0.7124	0.7128	0.6065	0.6668	0	0	1.0000
0.6749	0.8767	0.6543	0.7461	0	0	1.0000
0.3674	0.4359	0.4230	0.2965	1.0000	0	0
0.3473	0.0754	0.2183	0.1905	1.0000	0	0
0.6931	0.5188	0.5386	0.5794	0	1.0000	0
0.6439	0.4959	0.4322	0.4582	0	1.0000	0
0.5627	0.4893	0.6831	0.5120	0	1.0000	0

0.5182	0.7553	0.6368	0.4538	0	1.0000	0
0.6046	0.7479	0.6542	0.4375	0	1.0000	0
0.6328	0.6786	0.7751	0.6183	0	0	1.0000
0.3429	0.4694	0.2855	0.2977	1.0000	0	0
0.6371	0.5069	0.5316	0.4520	0	1.0000	0
0.6388	0.6970	0.6407	0.7677	0	0	1.0000
0.3529	0.5504	0.3706	0.4828	0	1.0000	0
0.4302	0.3237	0.6397	0.4319	0	1.0000	0
0.7078	0.9604	0.7470	0.6399	0	0	1.0000
0.7350	0.8170	0.7227	0.6279	0	0	1.0000
0.7011	0.2946	0.6625	0.4312	0	1.0000	0
0.5961	0.3817	0.6363	0.3663	0	1.0000	0
0	0.2563	0.2603	0.3027	1.0000	0	0
0.5996	0.5704	0.6965	0.6548	0	0	1.0000
0.4289	0.3709	0.3994	0.3656	0	1.0000	0
0.2093	0.3655	0.3334	0.1802	1.0000	0	0
0.2335	0.2856	0.3912	0.1601	1.0000	0	0
0.3266	0.7751	0.4356	0.3448	0	1.0000	0
0.2457	0.1203	0.1228	0.2206	1.0000	0	0
0.4656	0.4815	0.4211	0.4862	0	1.0000	0
0.7511	0.8868	0.5408	0.6253	0	0	1.0000
0.7825	0.9386	0.6510	0.6996	0	0	1.0000
0.3463	0.4118	0.2507	0.0454	1.0000	0	0
0.5172	0.1482	0.3172	0.2323	1.0000	0	0
0.6942	0.4516	0.5387	0.5983	0	1.0000	0
0.7586	0.7017	0.7120	0.7509	0	0	1.0000
0.6880	0.6004	0.6602	0.4320	0	1.0000	0
0.4742	0.5079	0.4135	0.4161	0	1.0000	0
0.4419	0.5761	0.4515	0.4497	0	1.0000	0
0.3367	0.4333	0.2336	0.1678	1.0000	0	0
0.4744	0.4604	0.1507	0.4873	1.0000	0	0
0.7510	0.4350	0.5453	0.4831	0	1.0000	0
0.4045	0.5636	0.2534	0.5573	0	1.0000	0
0.1449	0.1539	0.2446	0.0559	1.0000	0	0
0.3460	0.2722	0.1866	0.5049	1.0000	0	0
0.2241	0.2046	0.3575	0.2891	1.0000	0	0
0.1412	0.2264	0.4025	0.2661	1.0000	0	0
0.5782	0.6418	0.7212	0.6396	0	0	1.0000
0.9153	0.6571	0.8229	0.6689	0	0	1.0000
0.6014	0.7664	0.6385	0.5513	0	0	1.0000

0.7328	0.8708	0.8812	0.7060	0	0	1.0000
0.4270	0.6352	0.6811	0.3884	0	1.0000	0
0.6189	0.1652	0.4016	0.3042	1.0000	0	0
0.2143	0.3868	0.1926	0	1.0000	0	0
0.5696	0.7238	0.7199	0.6677	0	0	1.0000
0.8656	0.6700	0.6570	0.6065	0	0	1.0000
0.9002	0.6858	0.7409	0.7047	0	0	1.0000
0.4167	0.5255	0.5506	0.4093	0	1.0000	0
0.8325	0.4804	0.7990	0.7471	0	0	1.0000
0.4124	0.1191	0.4720	0.3184	1.0000	0	0
1.0000	1.0000	0.7924	0.7074	0	0	1.0000
0.5685	0.6924	0.6180	0.5792	0	1.0000	0
0.6505	0.4864	0.2972	0.4599	0	1.0000	0
0.8124	0.7690	0.9720	1.0000	0	0	1.0000
0.9013	0.7160	1.0000	0.8046	0	0	1.0000
0.8872	0.7556	0.9307	0.6791	0	0	1.0000
0.3708	0.2139	0.2136	0.4295	1.0000	0	0
0.5159	0.4349	0.3715	0.4086	0	1.0000	0
0.6768	0.6304	0.8044	0.4885	0	0	1.0000
0.1664	0.2404	0.2000	0.3425	1.0000	0	0
0.2495	0.2807	0.4679	0.2200	1.0000	0	0
0.2487	0.2348	0.0913	0.1281	1.0000	0	0
0.5748	0.8552	0.5973	0.7317	0	0	1.0000
0.3858	0.7585	0.3239	0.3565	0	1.0000	0
0.3329	0.4946	0.5614	0.3152	0	1.0000	0
0.3891	0.4805	0.7598	0.4231	0	1.0000	0
0.2888	0.4888	0.1930	0.0177	1.0000	0	0
0.3827	0.4900	0.2272	0.3599	0	1.0000	0
0.6047	0.4224	0.6274	0.5809	0	1.0000	0
0.9840	0.7031	0.6469	0.4701	0	0	1.0000
0.6554	0.6785	0.9279	0.7723	0	0	1.0000
0.0466	0.3388	0.0840	0.0762	1.0000	0	0
0.6154	0.8196	0.6339	0.7729	0	0	1.0000
0.8452	0.8897	0.8383	0.6961	0	0	1.0000
0.6927	0.7870	0.7689	0.7213	0	0	1.0000
0.4032	0.6188	0.4930	0.5380	0	1.0000	0
0.4006	0.3094	0.3868	0.0811	1.0000	0	0
0.7416	0.7138	0.6823	0.6067	0	0	1.0000
0.7404	0.6764	0.8293	0.4694	0	0	1.0000
0.7736	0.7097	0.6826	0.8142	0	0	1.0000

0.5823	0.9635	0.3706	0.5636	0	1.0000	0
0.2081	0.3738	0.3119	0.3552	1.0000	0	0
0.5616	0.8972	0.5186	0.6650	0	0	1.0000
0.6594	0.8907	0.6000	0.7157	0	0	1.0000
0.3979	0.3070	0.3637	0.1220	1.0000	0	0
0.2644	0	0.3572	0.1931	1.0000	0	0
0.4816	0.4791	0.4213	0.5889	0	1.0000	0
0.0848	0.0749	0.4349	0.3328	1.0000	0	0
0.4608	0.6775	0.3533	0.3016	0	1.0000	0
0.4155	0.6589	0.5310	0.5404	0	1.0000	0
0.3934	0.6244	0.4817	0.4324	0	1.0000	0
0.5843	0.8517	0.8576	0.7133	0	0	1.0000
0.1995	0.3690	0.3537	0.3462	1.0000	0	0
0.3832	0.2321	0.0341	0.2450	1.0000	0	0

ANEXO B - CONJUNTO DE TESTE

x1	x2	x3	x4	d1	d2	d3
0.8622	0.7101	0.6236	0.7894	0	0	1.0000
0.2741	0.1552	0.1333	0.1516	1.0000	0	0
0.6772	0.8516	0.6543	0.7573	0	0	1.0000
0.2178	0.5039	0.6415	0.5039	0	1.0000	0
0.7260	0.7500	0.7007	0.4953	0	0	1.0000
0.2473	0.2941	0.4248	0.3087	1.0000	0	0
0.5682	0.5683	0.5054	0.4426	0	1.0000	0
0.6566	0.6715	0.4952	0.3951	0	1.0000	0
0.0705	0.4717	0.2921	0.2954	1.0000	0	0
0.1187	0.2568	0.3140	0.3037	1.0000	0	0
0.5673	0.7011	0.4083	0.5552	0	1.0000	0
0.3164	0.2251	0.3526	0.2560	1.0000	0	0
0.7884	0.9568	0.6825	0.6398	0	0	1.0000
0.9633	0.7850	0.6777	0.6059	0	0	1.0000
0.7739	0.8505	0.7934	0.6626	0	0	1.0000
0.4219	0.4136	0.1408	0.0940	1.0000	0	0
0.6616	0.4365	0.6597	0.8129	0	0	1.0000
0.7325	0.4761	0.3888	0.5683	0	1.0000	0